주가예측보고서

CONTENTS.

 01
 개념설명
 02
 주가예측모델
 03
 결과

 04
 Python코드
 05
 한계점

01. 개념설명

DEEP LEARNING TENSORFLOW


DEEP LEARNING

머신러닝의 한 종류로, 대규모의 데이터에서 중요한 패턴 이나 규칙을 학습하고, 이를 토대로 예측을 하는 기술


TENSORFLOW

구글이 개발한 파이썬 딥러닝 오픈소스 라이브러리


LSTM.




one to many



many to one



many to many



RNN

-반복적이고 순차적인 데이터(Sequential data) 학습에 특화된 인공신경망의 한 종류

-데이터의 길이가 길어질 수록 앞쪽의 데이터 내용이 뒤쪽으로 전달되지 않는 '장기 의존성' 문제 **LSTM**

-'장기 의존성' 문제를 해결한 모델이 바로 LSTM (Long Short Term Memory network).

-LSTM은 Long-term Memory (장기기억)을 보존하는 능력이 있음. MANY-TO-ONE

-여러 데이터를 학습하여 하나의 결과값을 만들어 냄.

MANY-TO-MANY


-여러 데이터를 학습하여 여러 데이터를 예상하고, 예상한 데이터까지 학습하여 결과값을 만들어 냄.

MANY-TO-ONE을 선택한 이유

예상한 데이터가 오차가 있을 수 있는 문제 때문. 오차가 있는 데이터를 학습하여 결과값을 만들면 결과값은 더 큰 오차가 생김.

02. 주가예측모델

주가예측모델。



주가예측모델。

마지막 데이터 이후에 올 값 예측

데이터 = [1, 2, 3, 4, 5, 6, 7, 8, 9]


1 간격의 데이터를 학습하여 예상한 결과 [1,2,3,4,5,6,7,8,9] >>> 9.8

2 간격의 데이터를 학습하여 예상한 결과 [2,4,6,8] >>> 10.6

3 간격의 데이터를 학습하여 예상한 결과 [3,6,9] >>> 9.1

 $9.8 \times 0.7 + 10.6 \times 0.2 + 9.1 \times +0.1$ = 9.89

주가예측모델 •




03. Python E

MANY-TO-ONE LSTM MODEL CREATE THE RAW DATAFRAME.

```
# Get the stock quote
daily_raw_df = web.DataReader('AAPL', data_source='yahoo', start='2012-01-01', end='2021-08-18')
# 2일씩 가는 주가 예측 (dataset)
twodays_raw_df = daily_raw_df[len(daily_raw_df)::-2]
twodays_raw_df = twodays_raw_df[::-1]
# 3일씩 가는 주가 예측 (dataset)
threedays_raw_df = daily_raw_df[len(daily_raw_df)::-3]
threedays_raw_df = threedays_raw_df[::-1]
# 일주일씩 가는 주가 예측 (dataset)
# 장이 주말에는 운영이 안되므로 5일간격으로 dataset 만들어야 함
week_raw_df = daily_raw_df[len(daily_raw_df)::-5]
week_raw_df = week_raw_df[::-1]
# 이주일씩 가는 주가 예측 (dataset)
# 장이 주말에는 운영이 안되므로 10일간격으로 dataset 만들어야 함
twoweeks_raw_df = daily_raw_df[len(daily_raw_df)::-10]
twoweeks_raw_df = twoweeks_raw_df[::-1]
# 한달씩 가는 주가 예측 (dataset)
# 장이 주말에는 운영이 안되므로 20일간격으로 dataset 만들어야 함
month_raw_df = daily_raw_df[len(daily_raw_df)::-20]
month_raw_df = month_raw_df[::-1]
```

MANY-TO-ONE LSTM MODEL PLOT THE CLOSE PRICE HISTORY.



MANY-TO-ONE LSTM MODEL CREATE THE TRAIN DATASET.

```
# Create a new dataframe with only the 'Close column
daily_data = daily_raw_df.filter(['Close'])
twodays_data = twodays_raw_df.filter(['Close'])
threedays_data = threedays_raw_df.filter(['Close'])
week_data = week_raw_df.filter(['Close'])
twoweeks_data = twoweeks_raw_df.filter(['Close'])
month_data = month_raw_df.filter(['Close'])
# Convert the dataframe to a numpy array
daily_dataset = daily_data.values
twodays_dataset = twodays_data.values
threedays_dataset = threedays_data.values
week_dataset = week_data.values
twoweeks_dataset = twoweeks_data.values
month_dataset = month_data.values
# Get the number of rows to train the model on
training_data1_len = math.ceil(len(daily_dataset) * .8)
training_data2_len = math.ceil(len(twodays_dataset) * .8)
training_data3_len = math.ceil(len(threedays_dataset) * .8)
training_data7_len = math.ceil(len(week_dataset)
training_data14_len = math.ceil(len(twoweeks_dataset) * .8)
training_data28_len = math.ceil(len(month_dataset) * .8)
```

TRAIN DATASET

모델을 학습시키기 위한 데이터셋

TEST DATASET

학습에 전혀 관여하지 않고 오직 '최종 성능'을 평가하기 위한 데이터셋

TRAIN DATASET을 RAW DATASET의 80%를 하는 이유

학습세트와 검증세트를 어떤 비율로 분할할지 판단하는 것 중요함. 학습 세트가 너무 작으면 알고리즘이 효과적으로 학습하기에 충분치 않을 수 있고, 검증 데이터가 너무 작으면 정확도, 정밀도, 재현율 등이 서로 차이가 많이 나서 신뢰하기 어려울 수 있기 때문.

MANY-TO-ONE LSTM MODEL DATA SCALING.

```
# Scale the data
                                                                  # Split the data into x_train and y_train data sets
scaler = MinMaxScaler(feature_range=(0,1))
                                                                  x1_train = [] # 'x' will be the independent training variables or training features
                                                                  x2_{train} = []
scaled_data1 = scaler.fit_transform(daily_dataset)
                                                                  x3_train = []
scaled_data2 = scaler.fit_transform(twodays_dataset)
                                                                  x7 train = []
scaled_data3 = scaler.fit_transform(threedays_dataset)
                                                                  x14 train = []
                                                                  x28_train = []
scaled_data7 = scaler.fit_transform(week_dataset)
                                                                  y1_train = [] # 'y' will be the dependent variables or target variables
scaled_data14 = scaler.fit_transform(twoweeks_dataset)
                                                                  y2_{train} = []
scaled_data28 = scaler.fit_transform(month_dataset)
                                                                  y3_train = []
                                                                  y7_train = []
                                                                  y14_train = []
# Create the training data set
                                                                  y28_train = []
# Create the scaled training data set
                                                                  # 참고할(훈련시킬) 데이터 길이 ( 2000개 데이터일 때 60개로 잡은 기준으로 해서 비율 0.03으로 함- reference1기준)
train_data1 = scaled_data1[0:training_data1_len, :]
                                                                  # 데이터 사이즈가 너무 작을 수 있으므로 살짝씩 비율을 높여봄 -> 그냥 그대로 하는게 나은거 같기도 하고
train_data2 = scaled_data2[0:training_data2_len, :]
                                                                  reference1 = math.ceil(0.03*len(train_data1))
train_data3 = scaled_data3[0:training_data3_len, :]
                                                                  reference2 = math.ceil(0.05*len(train_data2))
                                                                  reference3 = math.ceil(0.07*len(train_data3))
train_data7 = scaled_data7[0:training_data7_len, :]
                                                                  reference7 = math.ceil(0.08*len(train_data7))
train_data14 = scaled_data14[0:training_data14_len, :]
                                                                  reference14 = math.ceil(0.09*len(train_data14))
train_data28 = scaled_data28[0:training_data28_len, :]
                                                                  reference28 = math.ceil(0.1*len(train_data28))
```

MANY-TO-ONE LSTM MODEL RESHAPE THE DATA

```
# Convert the x_train and y_train to numpy arrays for the LSTM model
x1_train, y1_train = np.array(x1_train), np.array(y1_train)
x2_train, y2_train = np.array(x2_train), np.array(y2_train)
x3_train, y3_train = np.array(x3_train), np.array(y3_train)
x7_train, y7_train = np.array(x7_train), np.array(y7_train)
x14_train, y14_train = np.array(x14_train), np.array(y14_train)
x28_train, y28_train = np.array(x28_train), np.array(y28_train)
```

```
# Reshape the data ( because LSTM model wants 3-dimensional data)

# print(x_train.shape) example-> result is (1543, 60), 2-dimension

x1_train = np.reshape(x1_train,(x1_train.shape[0],x1_train.shape[1],1))


x2_train = np.reshape(x2_train,(x2_train.shape[0],x2_train.shape[1],1))

x3_train = np.reshape(x3_train,(x3_train.shape[0],x3_train.shape[1],1))

x7_train = np.reshape(x7_train,(x7_train.shape[0],x7_train.shape[1],1))

x14_train = np.reshape(x14_train,(x14_train.shape[0],x28_train.shape[1],1))

x28_train = np.reshape(x28_train,(x28_train.shape[0],x28_train.shape[1],1))
```



DATA RESHAPING

LSTM 모델은 3차원의 텐서를 입력으로 받아야하므로 2차원의 데이터를 3차원의 데이터로 바꿈

After reshaping, print(x_train.shape) example -> result is (1543, 60, 1), 3-dimension 3차원의 데이터로 바꿈 # And to make the code robust, it is better to write the code instead of the number # for example, x_train.shape[0] instead of 1543

MANY-TO-ONE LSTM MODEL LSTM MODEL (ARCHITECTURE).

```
# Build the LSTM model (Architecture)
                                                                                     # Add 25neurons Dense layer, and this is your regularly densely connected
model1, model2, model3, model7, model14, model28 = \
                                                                                     # neural network layer with 25 neurons
   Sequential(), Sequential(), Sequential(), Sequential(), Sequential()
                                                                                     model1.add(Dense(25))
model1.add(LSTM(50, return_sequences=True, input_shape=_(x1_train.shape[1],1)))
                                                                                     model2.add(Dense(25))
model2.add(LSTM(50, return_sequences=True, input_shape=_(x2_train.shape[1],1)))
                                                                                     model3.add(Dense(25))
model3.add(LSTM(50, return_sequences=True, input_shape=_(x3_train.shape[1],1)))
                                                                                     model7.add(Dense(25))
model7.add(LSTM(50, return_sequences=True, input_shape=_(x7_train.shape[1],1)))
                                                                                     model14.add(Dense(25))
model14.add(LSTM(50, return_sequences=True, input_shape= (x14_train.shape[1],1)))
                                                                                     model28.add(Dense(25))
model28.add(LSTM(50, return_sequences=True, input_shape= (x28_train.shape[1],1)))
# Add second LSTM
                                                                                     model1.add(Dense(1))
model1.add(LSTM(50, return_sequences = False))
                                                                                     model2.add(Dense(1))
model2.add(LSTM(50, return_sequences = False))
model3.add(LSTM(50, return_sequences = False))
                                                                                     model3.add(Dense(1))
model7.add(LSTM(50, return_sequences = False))
                                                                                     model7.add(Dense(1))
model14.add(LSTM(50, return_sequences = False))
                                                                                     model14.add(Dense(1))
model28.add(LSTM(50, return_sequences = False))
                                                                                     model28.add(Dense(1))
```

LSTM 1st Layer : 50개의 뉴런 LSTM 2nd Layer : 50개의 뉴런 Dense 1st Layer : 25개의 뉴런 Dense 2nd Layer : 1개의 뉴런

MANY-TO-ONE LSTM MODEL

OPTIMIZER MODEL (ADAM - ADAPTIVE MOMENT ESTIMATION)

Optimizer 발전 과정

```
# Train the model

model1.fit(x1_train, y1_train, batch_size=1, epochs=3)


model2.fit(x2_train, y2_train, batch_size=1, epochs=3)

model3.fit(x3_train, y3_train, batch_size=1, epochs=3)

model7.fit(x7_train, y7_train, batch_size=1, epochs=3)

model14.fit(x14_train, y14_train, batch_size=1, epochs=3)

model28.fit(x28_train, y28_train, batch_size=1, epochs=3)
```




MODEL에 사용된 개념。

EPOCH

전체 데이터 셋에 대해 한번의 학습과정이 완료 된것 ex) epoch=40 -> 이건 전체 데이터를 40번 사용해서 학습하는 것

BATCH SIZE

한번의 epoch에서 모든 데이터를 한꺼번에 학습시킬 수 없음, 이때 몇번 나누어서 주는가 iteration, 각 interation 마다 주는 데이터 사이즈를 batch size 라고함



1 Epoch : 모든 데이터 셋을 한 번 학습

1 iteration : 1회 학습

minibatch: 데이터 셋을 batch size 크기로 쪼개서 학습


```
reference1 = math.ceil(0.03*len(train_data1))
reference2 = math.ceil(0.05*len(train_data2))
reference3 = math.ceil(0.07*len(train_data3))
reference7 = math.ceil(0.08*len(train_data7))
reference14 = math.ceil(0.09*len(train_data14))
reference28 = math.ceil(0.1*len(train_data28))
```

04. 31.


적용한 변수들과 최적의 모델。

```
# Build the LSTM model (Architecture)
                                                            model1, model2, model3, model7, model14, model28 = \
reference1 = math.ceil(0.03*len(train data1))
                                                                Sequential(), Sequential(), Sequential(), Sequential(), Sequential()
                                                            model1.add(LSTM(50, return sequences=True, input shape= (x1 train.shape[1],1)))
reference2 = math.ceil(0.05*len(train_data2))
                                                            model2.add(LSTM(50, return_sequences=True, input_shape=_(x2_train.shape[1],1)))
reference3 = math.ceil(0.07*len(train data3))
                                                            model3.add(LSTM(50, return_sequences=True, input_shape= (x3_train.shape[1],1)))
reference7 = math.ceil(0.08*len(train data7))
                                                            model7.add(LSTM(50, return_sequences=True, input_shape=_(x7_train.shape[1],1)))
                                                            model14.add(LSTM(50, return_sequences=True, input_shape=_(x14_train.shape[1],1)))
reference14 = math.ceil(0.09*len(train_data14))
                                                            model28.add(LSTM(50, return sequences=True, input shape= (x28 train.shape[1],1)))
reference28 = math.ceil(0.1*len(train data28))
                                                            # Add second LSTM
                                                            model1.add(LSTM(50, return_sequences = False))
                                                            model2.add(LSTM(50, return_sequences = False))
# Weight 시정
                                                            model3.add(LSTM(50, return_sequences = False))
print("="*23 + " 2021.08.19 PRICE RESULT " + "="*23)
                                                            model7.add(LSTM(50, return_sequences = False))
print(0.6*pred_price1 + \
                                                            model14.add(LSTM(50, return_sequences = False))
                                                            model28.add(LSTM(50, return_sequences = False))
      0.2*pred_price2 + \
      0.1*pred_price3 + \
                                                        # Train the model
      0.06*pred_price7 + \
                                                        model1.fit(x1_train, y1_train, batch_size=1, epochs=1)
      0.03*pred_price14 + \
                                                        model2.fit(x2_train, y2_train, batch_size=1, epochs=1)
      0.01*pred_price28)
                                                        model3.fit(x3_train, y3_train, batch_size=1, epochs=1)
                                                        model7.fit(x7_train, y7_train, batch_size=1, epochs=1)
                                                        model14.fit(x14_train, y14_train, batch_size=1, epochs=1)
                                                        model28.fit(x28_train, y28_train, batch_size=1, epochs=1)
```

적용한 변수들과 최적의 모델。



결과 MCDONALD INC。




결과 MCDONALD INC。

Date	Open	High	Low	Close*	Adj Close**	Volume
Aug 20, 2021	236.96	239.39	236.32	238.49	238.49	1,989,700
Aug 19, 2021	236.68	238.12	236.07	237.23	237.23	1,455,400
Aug 18, 2021	239.44	239.76	237.78	238.08	238.08	2,215,500

[[231.36852]]

결과 THE WALT DISNEY COMPANY。




결과 THE WALT DISNEY COMPANY。

________= 2021.08.19 PRICE RESULT ===========================

Date	Open	High	Low	Close*	Adj Close**	Volume
Aug 20, 2021	173.00	175.21	172.65	175.12	175.12	6,230,800
Aug 19, 2021	174.00	174.68	172.56	173.25	173.25	8,478,600
Aug 18, 2021	175.90	176.79	174.50	174.74	174.74	7,063,500

[[176.59645]]

결과 NIKE INC。




결과 NIKE INC。

Date	Open	High	Low	Close*	Adj Close**	Volume
Aug 20, 2021	166.27	168.01	165.42	167.79	167.79	4,039,100
Aug 19, 2021	166.96	167.54	164.37	165.59	165.59	7,336,300
Aug 18, 2021	169.75	171.80	168.66	168.81	168.81	5,487,400

[[159.26294]]

05。 さける

모델의한계。



LSTM을 이용한 예측이 Lagging 되는 현상

THANK YOU.